Lokalne anomalie i maskowanie odstających obiektów w LOF

Etap 1: publikacja, podstawy metody i plan badania

Projekt z Rozpoznawania wzorców
Rok akademicki 2026/2027

Prezentacja na 10-15 minut. Dodatki na końcu: protokół i informacja o AI.

Problem i cel projektu

Anomalia lokalna

Punkt może odbiegać od najbliższego otoczenia mimo niewielkiej odległości od innych danych.

Maskowanie

Zwarta grupa anomalii może tworzyć własne gęste sąsiedztwo i otrzymywać małe wyniki LOF.

Cel

Sprawdzić, kiedy zmiana liczby sąsiadów k pozwala ujawnić taką grupę.

[1] Sekcje 3-4. Plan badania: propozycja własna

Publikacja i zakres odtworzenia

LOF: Identifying Density-Based Local Outliers
M. M. Breunig, H.-P. Kriegel, R. T. Ng, J. Sander (2000)

Fragment do odtworzenia

Sekcja 3, rys. 1: idea lokalnej anomalii przy różnych gęstościach. Sekcja 4: obliczenia LOF.

Uzgadniana adaptacja

Własny generator 2D zamiast dokładnego zbioru DS1. Porównanie jakościowe, bez deklarowania replikacji liczb autorów.

[1] Breunig i in., SIGMOD 2000, s. 93-104

Sąsiedztwo i odległość osiągalności

k - liczba sąsiadów, **d(p,o)** - odległość euklidesowa.
k-distance(o) - odległość punktu o od jego k-tego sąsiada.
$\mathbf{N_k(p)}$ - sąsiedzi w tej odległości od p, bez samego p.

$$\mathbf{reach\text{-}dist_k(p,o) = max \{ k\text{-}distance(o), d(p,o) \}}$$

Odległość osiągalności ogranicza wpływ bardzo małych odległości wewnątrz gęstej grupy.
Zależy od sąsiada o, więc nie musi być symetryczna.

Przy remisach na granicy oryginalna definicja dopuszcza więcej niż k sąsiadów.

[1] Sekcja 4, definicje 3-5

Gęstość lokalna i wynik LOF

$lrd_k(p)$ to odwrotność średniej odległości osiągalności od p do punktów w $N_k(p)$.

$LOF_k(p)$ = średnia $lrd_k(o)$ / $lrd_k(p)$ dla o należących do $N_k(p)$

Około 1: podobna gęstość jak u sąsiadów.
Znacznie powyżej 1: mniejsza gęstość niż u sąsiadów.
Wynik służy do rankingu. Sam w sobie nie jest prawdopodobieństwem.

[1] Sekcja 4, definicje 6-7

Mały przykład obliczeniowy

Punkty na prostej: A = 0, B = 1, C = 3, P = 10. Przyjmujemy k = 2.

Punkt	Sąsiedzi	k-distance	lrd	LOF
A	B, C	3	0,400	0,917
B	A, C	2	0,333	1,200
C	B, A	3	0,400	0,917
P	C, B	9	0,125	2,933

Obliczenia własne według [1]. Sprawdzenie kodem NumPy

Obliczenie wyniku dla punktu P

1. Odległości osiągalności

Do C: max(3, 7) = 7. Do B: max(2, 9) = 9.

2. Gęstość lokalna

lrd(P) = 1 / ((7 + 9) / 2) = 0,125.

3. Porównanie z sąsiadami

LOF(P) = ((0,400 + 0,333...) / 2) / 0,125 = 2,933...

Sąsiedzi mają średnio około 2,93 razy większą gęstość lokalną niż P.

Obliczenia własne. Wartości zaokrąglone tylko do prezentacji

Pytanie badawcze i hipotezy

Pytanie

Jak relacja między k a liczebnością m zwartej grupy anomalii wpływa na jej wykrywalność?

H1: maskowanie przy małym k

Gdy k < m i grupa jest odseparowana, jej punkty mogą porównywać się głównie ze sobą.

H2: zmiana sąsiedztwa

Dla k ≥ m sąsiedztwo musi wyjść poza grupę. Oczekuję poprawy wykrywania w części konfiguracji.

Hipotezy własne. Zmiana k nie musi powodować monotonicznej zmiany LOF [1, sekcja 6]

Dane syntetyczne i dwa eksperymenty

Element	Zaplanowany zakres
Adaptacja publikacji	400 punktów N((-3,0), 0,8²I), 100 punktów N((3,0), 0,2²I), anomalie w (0,3) i (3,0,8).
Badanie własne	400 punktów N((0,0), 0,55²I). Grupa m anomalii z N((4,0), 0,08²I).
Zmienne	m □ {5, 15, 30, 60}, k □ {5, 10, 20, 40, 80}.
Kontrola odporności	Powtórzenie badania własnego dla środka grupy (2,0). Pozostałe parametry bez zmian.

Generator własny. Rozkłady zapisane jako średnia i odchylenie standardowe w każdej osi

Porównania i miary oceny

Punkt odniesienia

Ranking według odległości do k-tego sąsiada. Ten sam zbiór i k co dla LOF.

Główne miary

Average Precision (AP) dla rankingu i recall@B przy stałym budżecie B = 20 wskazań. Anomalia jest klasą dodatnią.

Wyjaśnienie mechanizmu

Mediana LOF anomalii i punktów normalnych oraz udział sąsiadów anomalii należących do tej samej grupy.

Plan własny. Etykiety anomalii wynikają wyłącznie z generatora

Powtórzenia i kontrola błędów

Zamrożony plan

Ziarna 0-4 do rozwoju kodu. Ziarna 100-119 do oceny końcowej. Bez wyboru najlepszego k na wynikach końcowych.

Uczciwe porównanie

Obie metody dostają identyczne dane w każdym powtórzeniu. Średnia i odchylenie standardowe z 20 powtórzeń.

Rola etykiet i skali

Etykiety służą tylko do oceny. Jednostki obu osi są zgodne. Bez uczenia na etykietach i bez interpretacji wyniku jako predykcji nowych danych.

Plan protokołu przed oceną końcową. Badanie detekcji wewnątrz analizowanego zbioru

Mała próba uruchomienia

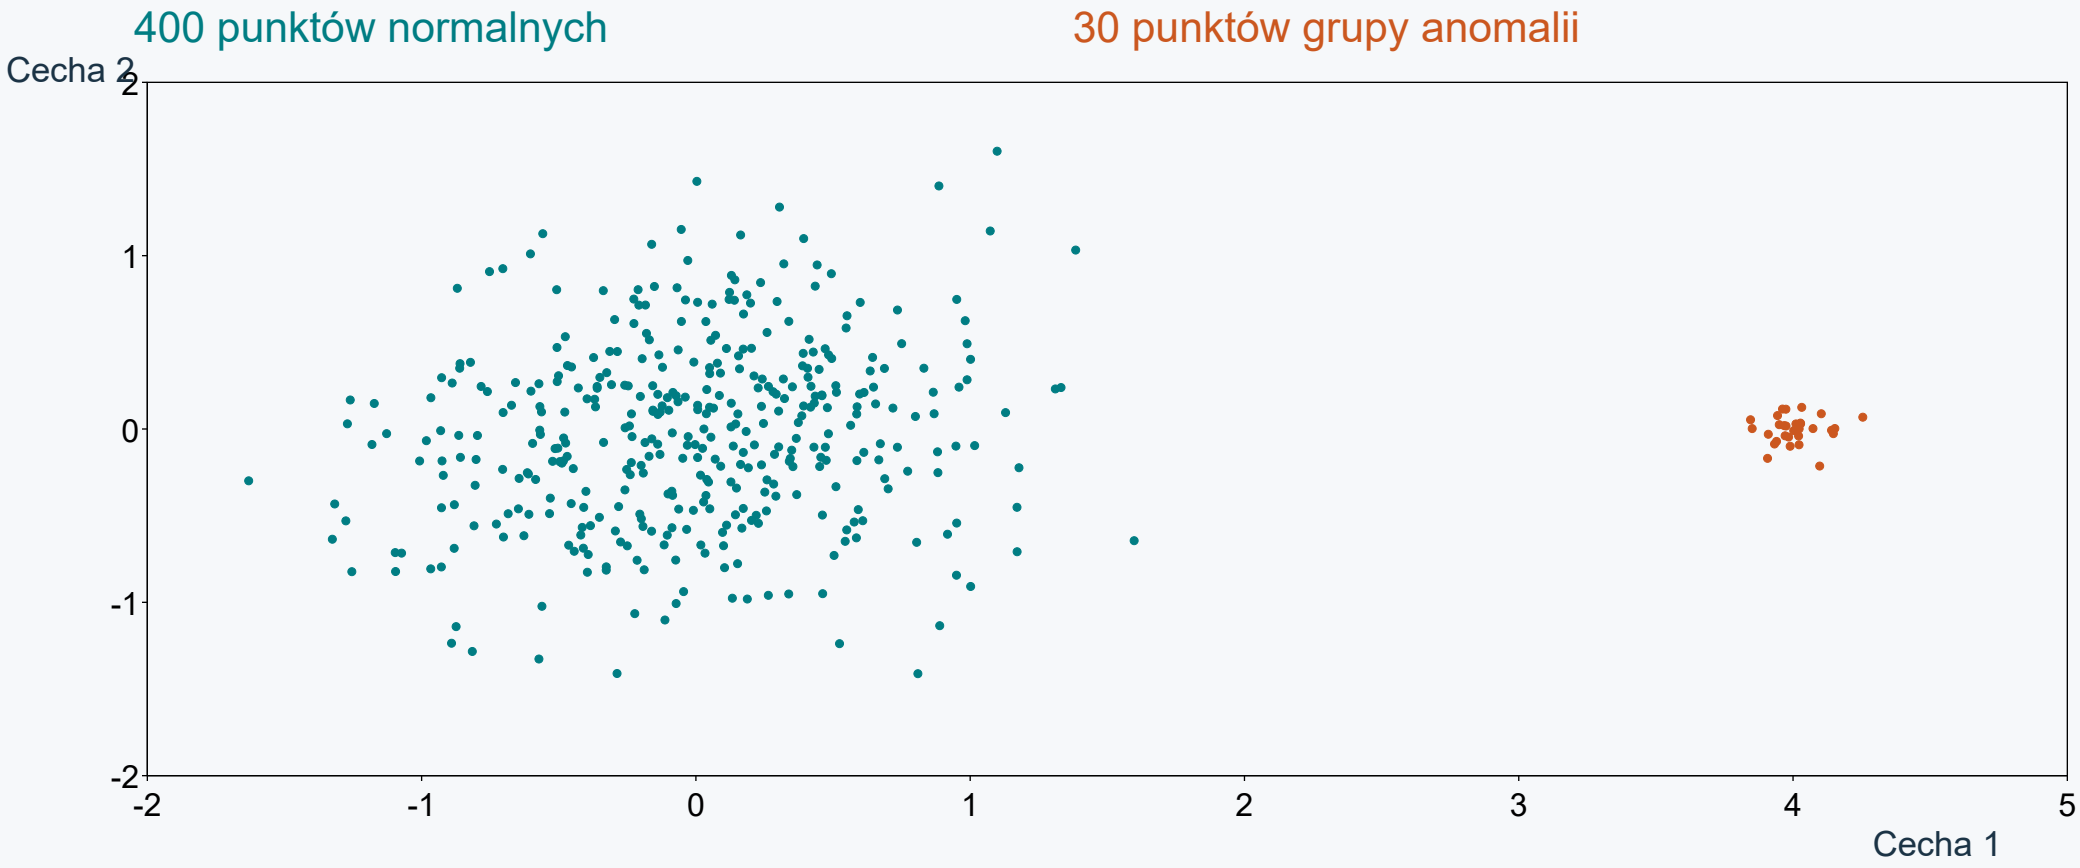
430 punktów 2D: 400 normalnych i 30 w zwartej grupie anomalii.
Python 3.12.14, NumPy 2.3.5. Implementacja według definicji LOF.

k	Mediana LOF normalnych	Mediana LOF anomalii	Recall@30
10	1.029	1.120	23.3%
40	1.026	1.994	83.3%

Oba uruchomienia: 0.024 s w tej sesji. Zapisano dane i surowe wyniki.
Recall@30 to pomocnicza miara demonstracyjna. Końcowy protokół używa B = 20.

Rzeczywiste obliczenia własne, seed = 42. Test wykonalności, poza pulą oceny końcowej

Dane użyte w próbie uruchomienia



Rzeczywiste dane z generatora własnego, seed = 42. Kolor oznacza etykietę generatora

Interpretacja próby i ograniczenia

Dla k = 10 mediana LOF grupy wyniosła 1.12,
a dla k = 40 wyniosła 1.99.

Co pokazuje próba

Zmiana sąsiedztwa może ujawnić zwartą grupę anomalii. To przesłanka do badania H1 i H2.

Czego wymaga interpretacja

Syntetyczna etykieta określa anomalię z założenia. Inna gęstość, odległość lub większe k mogą zmienić wynik. Potrzebne są powtórzenia.

Wyniki próby dotyczą jednego ziarna i jednej konfiguracji generatora

Wykonalność i plan dalszej pracy

Krok	Rezultat
Etap 1	Omówienie publikacji, ręczny przykład, próba kodu i uzgodnienie zakresu.
Etap 2	Adaptacja scenariusza lokalnych anomalii, punkt odniesienia i pierwsze wykresy.
Etap 3	Zamrożona ocena maskowania, analiza ograniczeń i raport 6-8 stron.

Wystarcza CPU. Maksymalnie 460 punktów w badaniu własnym.
Macierz odległości float64 zajmuje około 1,7 MB. Kod nie wymaga wag ani pobierania danych.

Zakres pozostaje propozycją do uzgodnienia z prowadzącym w etapie 1

Protokół badania - skrót do uzgodnienia

Pozycja	Ustalenie
Cel	Lokalne anomalie przy różnych gęstościach oraz maskowanie zwartej grupy.
Metoda i odniesienie	LOF według definicji [1], ranking odległości do k-tego sąsiada.
Odtworzenie / adaptacja	Sekcje 3-4, idea rys. 1. Własne dane 2D i jakościowa analiza rankingu.
Eksperyment własny	m = 5, 15, 30, 60. k = 5, 10, 20, 40, 80. Środek grupy: (4,0), kontrolnie (2,0).
Ocena	AP, recall@20, mediany LOF, udział sąsiadów z grupy. 20 ziaren końcowych 100-119.
Dokumentacja	Wersje środowiska, konfiguracje, ziarna, surowe wyniki CSV i instrukcja uruchomienia.

Dodatek A. Propozycja zakresu, nie zatwierdzona karta tematu

Źródła

[1] Breunig M. M., Kriegel H.-P., Ng R. T., Sander J. (2000).
LOF: Identifying Density-Based Local Outliers.
Proceedings of ACM SIGMOD, s. 93-104.
DOI: 10.1145/342009.335388

Pełny tekst publikacji (PDF)

[2] Dokumentacja scikit-learn: LocalOutlierFactor.
Opis implementacji bibliotecznej
Źródło pomocnicze. Próba w tej prezentacji korzysta z NumPy.

[3] Kontrakt przedmiotu „Rozpoznawanie wzorców”, 2026/2027.
Wymagania etapów i kryteria oceny. Plik przekazany przez studenta.

Dodatek B. Dostęp do źródeł internetowych: 26.10.2026

Informacja o wykorzystaniu AI

Narzędzie: OpenAI Codex, asystent generatywny.
Zakres wsparcia: porównanie tematów, opracowanie szkicu prezentacji, wyszukanie źródeł, przygotowanie kodu próby, obliczeń i redakcja materiału.

Student powinien przed oddaniem samodzielnie zweryfikować treść, uruchomić i zrozumieć kod oraz uzasadnić przyjęty plan badania. Wyniki próby pochodzą z wykonanych obliczeń.

Kontrakt wymaga informacji według załącznika 2A. Tego formularza nie było w przekazanych materiałach, dlatego ten slajd nie potwierdza zgodności z jego pełnym wzorem.

Dodatek C. Treść robocza do przeniesienia do uczelnianego formularza 2A